Алёна Егорова, 494, задание 2

In [73]:

```
import sklearn
from sklearn.naive_bayes import GaussianNB
from sklearn.naive_bayes import MultinomialNB
from sklearn.naive_bayes import BernoulliNB
from sklearn.model_selection import cross_val_score
import matplotlib.pyplot as plt
import pandas
%matplotlib inline
```

Посмотрим на датасеты

In [77]:

```
#  Первый датасет содержит в себе 1797 изображения размера 8*8,
#  где каждое изображение задано вектором размера 64
#  Каждый элемент вектора задает оттенок клеточки, как на рисунке ниже
#  Это и есть признаки
digits = sklearn.datasets.load_digits()
plt.figure(1, figsize=(3, 3))
plt.imshow(digits.images[0], cmap=plt.cm.gray_r, interpolation='nearest')
plt.show()
```

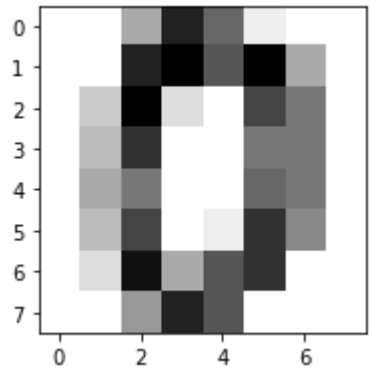

In [84]:

```
#  Посомотрим, как там представлены признаки
print(digits.data[:3])
```

```
[[  0.   0.   5.  13.   9.   1.   0.   0.   0.   0.  13.  15.  10.  1
5.
    5.   0.   0.   3.  15.   2.   0.  11.   8.   0.   0.   4.  12.
 0.
    0.   8.   8.   0.   0.   5.   8.   0.   0.   9.   8.   0.   0.
 4.
   11.   0.   1.  12.   7.   0.   0.   2.  14.   5.  10.  12.   0.
 0.
    0.   0.   6.  13.  10.   0.   0.   0.]
 [  0.   0.   0.  12.  13.   5.   0.   0.   0.   0.   0.  11.  16.
 9.
    0.   0.   0.   0.   3.  15.  16.   6.   0.   0.   0.   7.  15.  1
6.
   16.   2.   0.   0.   0.   0.   1.  16.  16.   3.   0.   0.   0.
 0.
    1.  16.  16.   6.   0.   0.   0.   0.   1.  16.  16.   6.   0.
 0.
    0.   0.   0.  11.  16.  10.   0.   0.]
 [  0.   0.   0.   4.  15.  12.   0.   0.   0.   0.   3.  16.  15.  1
4.
    0.   0.   0.   0.   8.  13.   8.  16.   0.   0.   0.   0.   1.
 6.
   15.  11.   0.   0.   0.   1.   8.  13.  15.   1.   0.   0.   0.
 9.
   16.  16.   5.   0.   0.   0.   0.   3.  13.  16.  16.  11.   5.
 0.
    0.   0.   0.   3.  11.  16.   9.   0.]]
```

В документации для digits dataset: "All input attributes are integers in the range 0..100. ". И мы действительно это видим: целые числа от 0 до 100.

In [81]:

```
#  Второй датасет представляет собой набор признаков (выведено ниже)
#  Классификацией является разделение опухоли на доброкачественную и злокачественну
breast_cancer = sklearn.datasets.load_breast_cancer()
print(breast_cancer.feature_names)
print(breast_cancer.target_names)
```

```
['mean radius' 'mean texture' 'mean perimeter' 'mean area'
 'mean smoothness' 'mean compactness' 'mean concavity'
 'mean concave points' 'mean symmetry' 'mean fractal dimension'
 'radius error' 'texture error' 'perimeter error' 'area error'
 'smoothness error' 'compactness error' 'concavity error'
 'concave points error' 'symmetry error' 'fractal dimension error'
 'worst radius' 'worst texture' 'worst perimeter' 'worst area'
 'worst smoothness' 'worst compactness' 'worst concavity'
 'worst concave points' 'worst symmetry' 'worst fractal dimension']
['malignant' 'benign']
```

In [83]:

```
print(breast_cancer.data[:3])
```

```
[[  1.79900000e+01   1.03800000e+01   1.22800000e+02   1.00100000e+03
    1.18400000e-01   2.77600000e-01   3.00100000e-01   1.47100000e-01
    2.41900000e-01   7.87100000e-02   1.09500000e+00   9.05300000e-01
    8.58900000e+00   1.53400000e+02   6.39900000e-03   4.90400000e-02
    5.37300000e-02   1.58700000e-02   3.00300000e-02   6.19300000e-03
    2.53800000e+01   1.73300000e+01   1.84600000e+02   2.01900000e+03
    1.62200000e-01   6.65600000e-01   7.11900000e-01   2.65400000e-01
    4.60100000e-01   1.18900000e-01]
 [  2.05700000e+01   1.77700000e+01   1.32900000e+02   1.32600000e+03
    8.47400000e-02   7.86400000e-02   8.69000000e-02   7.01700000e-02
    1.81200000e-01   5.66700000e-02   5.43500000e-01   7.33900000e-01
    3.39800000e+00   7.40800000e+01   5.22500000e-03   1.30800000e-02
    1.86000000e-02   1.34000000e-02   1.38900000e-02   3.53200000e-03
    2.49900000e+01   2.34100000e+01   1.58800000e+02   1.95600000e+03
    1.23800000e-01   1.86600000e-01   2.41600000e-01   1.86000000e-01
    2.75000000e-01   8.90200000e-02]
 [  1.96900000e+01   2.12500000e+01   1.30000000e+02   1.20300000e+03
    1.09600000e-01   1.59900000e-01   1.97400000e-01   1.27900000e-01
    2.06900000e-01   5.99900000e-02   7.45600000e-01   7.86900000e-01
    4.58500000e+00   9.40300000e+01   6.15000000e-03   4.00600000e-02
    3.83200000e-02   2.05800000e-02   2.25000000e-02   4.57100000e-03
    2.35700000e+01   2.55300000e+01   1.52500000e+02   1.70900000e+03
    1.44400000e-01   4.24500000e-01   4.50400000e-01   2.43000000e-01
    3.61300000e-01   8.75800000e-02]]
```

Выборка представлена действительными числами, которые могут быть меньше единицы

Сравним cross_val_score

Напишем функцию, которая принимает на вход байесовский классификатор и датасет. Возвращает среднее значение scoring='accuracy' (по умолчанию)

In [85]:

```
def compare_score(naive_bayes_estimator, dataset):
    estimator = naive_bayes_estimator
    score = cross_val_score(naive_bayes_estimator, dataset.data, dataset.target)

    return score.mean()
```

In [90]:

```
naive_bayes_estimators = [GaussianNB(), MultinomialNB(), BernoulliNB()]

for i in range(3):
    print(str(naive_bayes_estimators[i]))
    print('digits: ' +
          "{:.4f}".format(compare_score(naive_bayes_estimators[i], digits)))
    print('breast_cancer: ' +
          "{:.4f}".format(compare_score(naive_bayes_estimators[i], breast_cancer)))
    print('\n')
```

```
GaussianNB(priors=None)
digits: 0.8186
breast_cancer: 0.9367


MultinomialNB(alpha=1.0, class_prior=None, fit_prior=True)
digits: 0.8709
breast_cancer: 0.8946


BernoulliNB(alpha=1.0, binarize=0.0, class_prior=None, fit_prior=True)
digits: 0.8258
breast_cancer: 0.6274
```

Ответы на вопросы:

1. На **breast canser** максимальное значение получилось: 0.9367 (GaussianNB)
2. На **digits** максимальное значение получилось: 0.8709 (MultinormialNB)
3. (c), (d) - верные утверждения