3/9/2017 Task1

In [19]:

```
import pydotplus
import pandas as pd
from IPython.display import Image
from sklearn import tree
import matplotlib.pyplot as plt
from sklearn.cross_validation import train_test_split
from sklearn.metrics import accuracy_score, classification_report
from sklearn.model_selection import cross_val_score
```

In [20]:

```
dataset = pd.read_csv("german_credit.csv")
```

In [21]:

```
# Посмотрим на признаки и их значения
dataset.head()
```

Out[21]:

	target	Account Balance	Duration of Credit (month)	Payment Status of Previous Credit	Purpose	Credit Amount	Value Savings/Stocks	Length of current employment
0	1	1	18	4	2	1049	1	2
1	1	1	9	4	0	2799	1	3
2	1	2	12	2	9	841	2	4
3	1	1	12	4	0	2122	1	3
4	1	1	12	4	0	2171	1	3

5 rows × 21 columns

Строим дерево с помощью sklearn

In [22]:

```
model = tree.DecisionTreeClassifier(max_depth=4)
model.fit(dataset[dataset.columns[1:]], dataset[dataset.columns[0]])
```

Out[22]:

```
DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=
4,
```

```
max_features=None, max_leaf_nodes=None,
min_impurity_split=le-07, min_samples_leaf=1,
min_samples_split=2, min_weight_fraction_leaf=0.0,
presort=False, random_state=None, splitter='best')
```


3/9/2017 Task1

In [23]:

In [24]:

```
graph = pydotplus.graphviz.graph_from_dot_file("tree.out")
Image(graph.create_png())
```

Out[24]:



Я сделала максимальную высоту дерева = 4, иначе ничего не видно.

Проинтерпретируем первые разбиения

Первый признак разбиения: первым делом проверяется размер счета сейчас. Потом в зависимости от его размера спрашивается срок данного кредита или же сведения о нынешней занятости. Вполне логично.

Оценим качество

In [25]:

In [26]:

```
model.fit(train_data, train_target)
```

Out[26]:

In [27]:

```
test_predictions = model.predict(test_data)
```

3/9/2017 Task1

In [28]:

```
print(classification_report(test_target, test_predictions))
                           recall f1-score
             precision
                                                support
          0
                   0.60
                             0.49
                                        0.54
                                                     57
          1
                   0.81
                             0.87
                                        0.84
                                                    143
avg / total
                   0.75
                             0.76
                                        0.75
                                                    200
```

Графики зависимости качества на кросс-валидации и на обучающей выборке от глубины дерева

In [29]: